جزوه دوره مهندسی داده و مهندسی هوش مصنوعی

Data Engineering & AI Engineering

یادداشت‌های آموزشی، مفاهیم فنی و تمرین‌های دوره



تاریخ به روز رسانی : 20261018

درباره این جزوه

این جزوه با هدف ثبت، سازمان‌دهی و بازنویسی آموزشی مطالب دوره رایگان «مهندسی داده و مهندسی هوش مصنوعی» تهیه شده است.

محتوای آن بر اساس توضیحات مدرس، مثال‌های مطرح‌شده در کلاس و پرسش‌وپاسخ‌های آموزشی تدوین می‌شود. تلاش شده است مطالب گفتاری کلاس به متنی منظم، قابل فهم و مناسب مطالعه مستقل تبدیل شوند، بدون اینکه مفهوم اصلی صحبت‌های مدرس تغییر کند.

هدف این جزوه صرفاً خلاصه‌کردن جلسات نیست؛ بلکه ایجاد یک منبع آموزشی است که دانشجو بتواند در طول دوره و حتی چند ماه پس از پایان آن، برای یادگیری دوباره مفاهیم، مرور نکات فنی و آماده‌شدن برای فعالیت‌های عملی به آن مراجعه کند.

رویکرد آموزشی و شیوه تدوین

در تدوین مطالب، ابتدا مفاهیم اصلی هر جلسه با زبانی ساده و دقیق توضیح داده می‌شوند. سپس مثال‌های مدرس، کاربردهای عملی و ارتباط موضوعات با مسائل واقعی مهندسی داده و هوش مصنوعی بررسی می‌شوند.

برای حفظ دقت علمی و تمایز میان محتوای اصلی کلاس و توضیحات تکمیلی، از ساختار زیر استفاده شده است:

- **مطالب اصلی جلسه :**بازنویسی منظم توضیحات مدرس با حفظ مفهوم و مثال‌های اصلی.
- **تکمیل فنی :**توضیحات دقیق‌تر، اصلاح برداشت‌های احتمالی و نکات تکمیلی بر اساس منابع فنی معتبر.
- **مثال اضافی :**مثال‌ها و سناریوهایی که برای درک بهتر مفاهیم به جزوه افزوده شده‌اند.
- **نکات کاربردی :**ملاحظات اجرایی، محدودیت‌ها و تجربه‌های مرتبط با استفاده عملی از مفاهیم.
- **جمع‌بندی و سوال‌های مرور :**مرور مهم‌ترین مطالب و ارزیابی میزان یادگیری در پایان هر جلسه.

اصطلاحات تخصصی مانندData Pipeline ، Data Warehouse، ETL، Orchestrationو سایر مفاهیم فنی با نام اصلی انگلیسی حفظ شده‌اند تا مطالعه مستندات رسمی و منابع تخصصی برای دانشجویان آسان‌تر باشد.

محدوده و توسعه جزوه

این مجموعه به‌صورت تدریجی و هم‌زمان با انتشار جلسات جدید تکمیل می‌شود و دو مسیر اصلی دوره، یعنی Data Engineering و AI Engineering، را پوشش می‌دهد.

نسخه‌های به‌روزشده جزوه‌ها، منابع تکمیلی و یادداشت‌های هر جلسه از طریق مخزن عمومی GitHub در دسترس خواهند بود.

مخزن جزوه‌ها:

https://github.com/LaneZero/data-ai-engineering-course

وب‌سایت اصلی دوره:

https://mostafaghadimi.github.io/data-course/

یادداشت درباره اعتبار محتوا

این جزوه یک مجموعه آموزشی مستقل و غیررسمی است و وابستگی رسمی به مدرس یا برگزارکنندگان دوره ندارد.

حقوق محتوای اصلی دوره متعلق به صاحبان آن است. توضیحات تکمیلی و مثال‌های افزوده‌شده نیز لزوماً بیانگر دیدگاه یا تأیید مدرس نیستند.

با وجود تلاش برای حفظ دقت فنی، توصیه می‌شود هنگام اجرای پروژه‌های واقعی، اطلاعات حساس یا تصمیم‌گیری‌های فنی مهم، مستندات رسمی ابزارها و منابع اصلی نیز بررسی شوند.

هدف از انتشار این مجموعه، **کمک به یادگیری عمیق‌تر، مرور منظم مفاهیم و اشتراک دانش با علاقه‌مندان حوزه داده و هوش مصنوعی** است.

فهرست مطالب

هدف این جلسه چیست؟ 1

۱ .این دوره برای چه کسانی طراحی شده است؟ 1

۲ .نقش‌های شغلی در دنیای داده وAI 2

۱.۲ .تحلیلگر داده وBI Engineer 2

۲.۲ .دانشمند داده 2

۳.۲ .مهندس داده 3

۴.۲ .مهندس هوش مصنوعی 3

۵.۲ .دو نقش دیگر 3

۳ . Data-first در برابر AI-first 3

۴ .چرخه عمر مهندسی داده(Data Engineering Lifecycle) 4

مثال کلاس :سفارش‌های یک فروشگاه آنلاین 4

۵ .ذخیره‌سازی، معماری وSingle Source of Truth 4

۶.ETL ، ELT و شیوه‌های پردازش 5

۷. OLTP و OLAP چه تفاوتی دارند؟ 5

۸ .چرا اعتمادپذیری و پایش داده مهم است؟ 5

۹ .نقشه راه و ساختار ادامه دوره 6

۱۰ .تمرین‌ها، پروژه و شیوه یادگیری 6

۱۱ .پرسش‌های مهم مطرح‌شده در کلاس 6

۱۲ .منابع پیشنهادی مدرس 7

۱۳ .جمع‌بندی جلسه 7

۱۴ .چک‌لیست مرور 8

۱۵ .سوال‌های مرور 8

جلسه ۱ :آشنایی با مهندسی داده و مهندسی هوش مصنوعی

تاریخ :(۱۸ اکتبر ۲۰۲۶) ۲۶ مهر ۱۴۰۵
دوره :مهندسی داده و مهندسی هوش مصنوعی
مدرس جلسه :مصطفی قدیمی
نوع جلسه :معرفی دوره، نقش‌های شغلی، مفاهیم پایه و نقشه راه

راهنمای مطالعه :متن اصلی، روایت آموزشی صحبت‌های مدرس است .هرجا توضیح یا اصلاحی فراتر از صحبت کلاس لازم بوده، با عنوان **تکمیل فنی** «یا» **مثال اضافی** مشخص شده است .این جلسه آموزشی و مقدماتی است؛ قرار نیست همه ابزارهایی را که نام برده شده‌اند همین حالا یاد بگیریم.

هدف این جلسه چیست؟

در اولین جلسه هنوز سراغ نصب ابزار و نوشتن کد نمی‌رویم .قرار است تصویری کلی از حوزه داده و هوش مصنوعی پیدا کنیم :چه شغل‌هایی در این حوزه وجود دارند، مهندس داده دقیقاً چه مشکلی را حل می‌کند، مهندس هوش مصنوعی چه می‌سازد و مسیر ادامه دوره چگونه است .مدرس توضیح می‌دهد که دوره هم برای کسانی طراحی شده که تازه وارد این حوزه می‌شوند و هم برای افرادی که سابقه کار در نقش‌های دیگر، مانند توسعه نرم‌افزار، دارند و می‌خواهند مسیرشان را تغییر دهند.

رویکرد دوره این است که ابتدا چرایی و مفهوم را یاد بگیریم، بعد سراغ ابزار برویم .یک ابزار ممکن است جایگزین شود، ولی نیاز به داده قابل اعتماد، طراحی سیستم و ارزیابی خروجی همچنان باقی می‌ماند .دوره رایگان و آنلاین است؛ مدرس بر یادگیری جمعی، تمرین فردی، پروژه گروهی و ارتباط میان دانشجوها و منتورها تأکید می‌کند.

۱ .این دوره برای چه کسانی طراحی شده است؟

مدرس چهار دسته از مخاطبان را در نظر می‌گیرد :دانشجویان و تازه‌واردها، افرادی که می‌خواهند از نقش‌های شغلی دیگر وارد حوزه داده یا AI شوند، جویندگان کار و کسانی که می‌خواهند درک کلی‌تری از کار تیم‌های داده و هوش مصنوعی به دست آورند .هدف دوره تضمین استخدام نیست .آموزش، تمرین، پروژه و شبکه‌سازی می‌توانند کمک کنند فرد مسیرش را بهتر انتخاب کند و توانایی خود را نشان دهد.

در شرکت‌های کوچک گاهی یک نفر چند مسئولیت را هم‌زمان برعهده دارد؛ در سازمان‌های بزرگ‌تر معمولاً تیم‌های تخصصی‌تر شکل می‌گیرند .بنابراین عنوان شغلی به‌تنهایی شرح وظیفه دقیق و یکسانی در همه شرکت‌ها ایجاد نمی‌کند.

نکته مدرس :آشنایی با مفاهیم، از حفظ کردن فهرستی طولانی از ابزارها مفیدتر است .قرار نیست هر شرکت از جدیدترین فناوری بازار استفاده کند.

۲ .نقش‌های شغلی در دنیای داده وAI

نقش	مسئله اصلی	نمونه‌ای از کلاس
Data Analyst / BI Engineer	توصیف و تحلیل وضعیت کسب‌وکار با داده موجود	چرا فروش ماه قبل کاهش یافت؟
Data Scientist	کشف الگو، مدل‌سازی و در بسیاری از پروژه‌ها پیش‌بینی	فروش آینده یا احتمال خرید مشتری چقدر است؟
Data Engineer	ساخت و نگهداری جریان داده قابل اعتماد برای مصرف‌کنندگان	یکپارچه‌کردن داده خرید و مشتری برای کمپین
AI Engineer	ساخت محصول و قابلیت کاربردی با مدل‌های هوش مصنوعی	ساخت دستیار یا محصول مبتنی بر مدل
Inference Engineer	بهینه‌سازی اجرای مدل، تأخیر، هزینه و مصرف منابع	انتخاب روش اجرای سریع‌تر و ارزان‌تر مدل
Forward-Deployed Engineer	حل مسئله مشتری در بستر فرایند واقعی او	شناخت فرایند پرداخت خسارت شرکت بیمه و ساخت راه‌حل

۱.۲ .تحلیلگر داده وBI Engineer

اگر مدیر یک فروشگاه آنلاین بپرسد چرا فروش ماه گذشته افت کرده؟، تحلیلگر می‌تواند داده‌های سفارش، محصول، مشتری و دوره زمانی را بررسی کند، شاخص‌ها را محاسبه کند و از گزارش یا Dashboard برای توضیح نتیجه استفاده کند .در این کار، فهم سؤال کسب‌وکار و تشخیص داده درست به اندازه ابزار مهم است.

۲.۲ .دانشمند داده

دانشمند داده می‌تواند از داده‌های تاریخی برای شناسایی الگو و ساخت مدل استفاده کند؛ برای مثال پیش‌بینی کند کدام گروه از مشتریان احتمال بیشتری دارد در کمپین بعدی خرید کنند .عملکرد مدل باید با روش مناسب ارزیابی شود؛ صرف تولید یک عدد پیش‌بینی کافی نیست.

تکمیل فنی :تقسیم‌بندی Analyst» فقط گذشته را می‌بیند و Data Scientist فقط آینده را پیش‌بینی می‌کند «یک ساده‌سازی آموزشی است، نه مرز قطعی حرفه‌ها .تحلیلگر هم می‌تواند پیش‌بینی انجام دهد و دانشمند داده هم تحلیل توصیفی، آزمایش و استنتاج انجام می‌دهد .شرح دقیق نقش‌ها به سازمان و پروژه بستگی دارد.

۳.۲ .مهندس داده

نقش مهندس داده این است که داده‌های پراکنده را به شکلی قابل استفاده، قابل اعتماد و قابل دسترس برای تحلیلگران، دانشمندان داده، تیم محصول و دیگر مصرف‌کنندگان آماده کند .برای مثال اگر اطلاعات سفارش در Databaseعملیاتی، اطلاعات کمپین در یک فایل و داده مشتریان در منبع دیگری باشد، استفاده تحلیلی از آن‌ها به یک جریان منظم نیاز دارد.

نباید نتیجه بگیریم که بدون Data Engineer هیچ داده‌ای تولید نمی‌شود .برنامه‌نویسان Backend و سیستم‌های عملیاتی معمولاً داده تراکنش را ایجاد می‌کنند؛ مسئله مهندسی داده، فراهم کردن بستر مناسب مصرف تحلیلی و سایر کاربردهای داده است.

۴.۲ .مهندس هوش مصنوعی

AI Engineerغالباً با استفاده از مدل‌های موجود،Prompt ، ابزارها، اتصال به داده و سرویس‌ها، Guardrail و ارزیابی خروجی، یک قابلیت یا محصول می‌سازد .ساخت مدل از صفر تنها یکی از مسیرهای ممکن است و برای همه پروژه‌ها لازم نیست .علاوه بر کیفیت پاسخ، هزینه اجرا، پایش، امنیت و تجربه کاربر مهم هستند.

۵.۲ .دو نقش دیگر

Inference Engineerبیشتر بر اجرای مدل در مقیاس مناسب، منابع محاسباتی، زمان پاسخ و هزینه تمرکز می‌کند . Forward-Deployed Engineerدر کنار مشتری یا تیم عملیاتی، مسئله واقعی و فرایند کاری را می‌شناسد و به پیاده‌سازی راه‌حل کمک می‌کند .مدرس به این نقش‌ها برای آشنایی اشاره کرد، نه به‌عنوان مسیر اصلی آموزشی این جلسه.

۳ . Data-first در برابر AI-first

در کلاس دو رویکرد مطرح شد .در نگاه **Data-first** ابتدا برای کیفیت، دسترسی، تعریف و مدیریت داده سرمایه‌گذاری می‌کنیم تا سامانه‌ها و افراد بر پایه‌ای قابل اتکا کار کنند .در نگاه **AI-first** تلاش می‌شود قابلیت‌های هوش مصنوعی در مرکز طراحی محصول یا فرایند قرار گیرد .مدرس برای این دوره، توجه به زیرساخت داده را مسیر آموزشی بنیادی انتخاب کرده است.

تکمیل فنی: Data-first و AI-first دو معماری کاملاً متضاد یا استاندارد رسمی با یک تعریف ثابت نیستند .یک محصول موفق ممکن است هم طراحیAI محور داشته باشد و همGovernance ، کیفیت داده، دسترسی کنترل‌شده و ارزیابی دقیق .اتصال مستقیم مدل بهDatabase ، بدون کنترل مجوز، حریم خصوصی و صحت خروجی، ریسک دارد.

مدرس در بحث آینده شغل‌ها تأکید می‌کند که با وجود رشدCoding Agent ها، هنوز توانایی تعریف مسئله، تشخیص خطا و سنجش خروجی ارزش دارد .این بخش بیان دیدگاه مدرس درباره وضعیت فعلی است، نه پیش‌بینی قطعی بازار کار.

۴ .چرخه عمر مهندسی داده(Data Engineering Lifecycle)

منبع مفهومی اصلی مدرس، کتاب **Fundamentals of Data Engineering** است .در جلسه پنج بخش چرخه عمر با نام‌های زیر معرفی شدند:

1. **Generation:** داده در سیستم عملیاتی، رویدادهای کاربر، فایل، API یا منبع دیگر تولید می‌شود.
2. **Storage:** داده در فضای ذخیره‌سازی مناسب نگهداری می‌شود؛ ذخیره‌سازی می‌تواند در نقاط مختلف جریان داده حضور داشته باشد.
3. **Ingestion:** داده از منبع دریافت یا منتقل می‌شود.
4. **Transformation:** داده پاک‌سازی، تبدیل، استاندارد یا ترکیب می‌شود.
5. **Serving:** داده برای مصرف در تحلیل، گزارش، علم داده یا محصول در دسترس قرار می‌گیرد.

این پنج نام مرحله، یک چارچوب مفهومی هستند، نه اینکه هر Pipeline دقیقاً همیشه به یک ترتیب فیزیکی ثابت اجرا شود .به‌ویژه Storage می‌تواند هم در مبدأ و هم در لایه‌های میانی و مقصد وجود داشته باشد.

مثال کلاس :سفارش‌های یک فروشگاه آنلاین

مشتری سفارش می‌دهد و برنامه Backend سفارش را در Database عملیاتی ثبت می‌کند .داده سفارش همراه با فایل‌ها یا منابع دیگر وارد جریان مهندسی داده می‌شود؛ اگر یک منبع قیمت را به ریال و دیگری به تومان نگه دارد، باید واحدها با تعریف روشن یکسان شوند .در پایان، تیم تحلیل یا کمپین بتواند داده مناسب را ببیند و روی آن تصمیم بگیرد.

تکمیل فنی :تبدیل واحد پولی نباید صرفاً با» حذف یک صفر «در رشته انجام شود .باید نوع عددی، واحد منبع، قواعد تبدیل و دقت مقادیر مشخص باشد .برای مثال در تبدیل ریال به تومان معمولاً تقسیم عددی بر ۱۰ مطرح است؛ در داده مالی کنترل Precision و تعریف واحد ضروری است.

۵ .ذخیره‌سازی، معماری وSingle Source of Truth

مدرس نام چند الگوی مهم را معرفی می‌کند **Data Warehouse** :برای داده ساختارمند و تحلیل، **Data Lake** برای نگهداری انواع داده در قالب‌های متنوع و **Lakehouse** برای ترکیب برخی قابلیت‌های Lake و .Warehouse همچنین از **Data Mesh**به‌عنوان رویکردی در سازمان‌دهی مسئولیت داده یاد می‌کند .جزئیات این معماری‌ها قرار است در جلسه‌های تخصصی باز شود.

Single Source of Truthدر مثال کلاس یعنی مصرف‌کنندگان داده، تا حد ممکن از تعریف‌ها و منابع معتبر و هماهنگ استفاده کنند .این عبارت لزوماً به معنی ریختن همه داده‌های خام سازمان در یک Database فیزیکی نیست.

تکمیل فنی :برای داشتن» منبع حقیقت «باید مالکیت داده، تعریف شاخص‌ها، تازگی اطلاعات، دسترسی، Lineageو سازگاری داده‌ها روشن باشد .صرفاً کپی‌کردن فایل‌ها در یک محل، به‌تنهایی مشکل اختلاف گزارش‌ها را حل نمی‌کند.

۶.ETL ، ELT و شیوه‌های پردازش

دو ترتیب عمومی انتقال و تبدیل معرفی شد:

```
ETL: Extract → Transform → Load
ELT: Extract → Load → Transform
```

در **ETL** معمولاً تبدیل پیش از بارگذاری نهایی به مقصد انجام می‌شود؛ در **ELT** داده ابتدا در مقصد بارگذاری می‌شود و تبدیل در همان محیط یا لایه‌های بعدی انجام می‌گیرد .مدرس همچنین ازBatch Processing ، Stream Processing و CDCنام برد، اما توضیح عمیق آن‌ها را به جلسات آینده موکول کرد.

تکمیل فنی ETL/ELT :توصیف یک ترتیب منطقی هستند و انتخاب بین آن‌ها به معماری، ابزار، الزامات امنیتی، هزینه و محل پردازش بستگی دارد .Stream Processing نیز الزاماً به معنی پردازش تک‌تک رویدادها بدون هیچ تأخیری نیست.

۷. OLTP و OLAP چه تفاوتی دارند؟

مدرس به سیستم‌های عملیاتی مانند بانک و فروشگاه اشاره کرد .در سیستم‌های **OLTP** تراکنش و ثبت عملیات روزمره اهمیت زیادی دارد؛ برای مثال ثبت سفارش یا انتقال وجه .در محیط‌های **OLAP** نیاز اصلی معمولاً اجرای تحلیل روی حجم زیادی از داده و پرسش‌های تجمیعی است .این تفاوت کمک می‌کند بفهمیم چرا همیشه نباید گزارش‌های سنگین را مستقیماً از Database عملیاتی تولید کنیم.

تکمیل فنی OLTP و OLAP دو نوع الگوی بارکاری‌اند، نه برچسب‌هایی که برای هر Database همیشه و به‌طور کامل ثابت باشند .قابلیت‌های ACID نیز باید در سطح پیاده‌سازی و تنظیمات یک سیستم بررسی شوند.

۸ .چرا اعتمادپذیری و پایش داده مهم است؟

مهندس داده صرفاً داده را جابه‌جا نمی‌کند .اگر Pipeline متوقف شود، داده دیر برسد، ردیف‌ها تکراری باشند یا مقدارها در تبدیل اشتباه شوند، تصمیم نهایی هم ممکن است آسیب ببیند .مدرس این موضوع را با مثال نشتی در لوله انتقال داده توضیح می‌دهد .از همین‌جا اهمیت **Data Quality** و **Observability** روشن می‌شود.

مثال اضافی :اگر انتظار داریم روزانه ۱۰۰ هزار سفارش دریافت کنیم ولی امروز تنها ۶۰ هزار ردیف رسیده، باید پیش از انتشار گزارش، تأخیر بارگذاری، خطای منبع یا تغییر واقعی فروش را بررسی کنیم .افت Row Count به‌خودی‌خود ثابت نمی‌کند فروش افت کرده است.

۹ .نقشه راه و ساختار ادامه دوره

مدرس مسیر دوره را از آشنایی مفهومی به کارگاه و پروژه پیش می‌برد .برخی جلسه‌ها مشترک‌اند و سپس مسیرهای **Data Engineering**و **AI Engineering** جدا می‌شوند .شرکت در هر دو مسیر ممکن است، ولی الزامی نیست.

بخش برنامه	انتظار آموزشی
پیش‌نیازها	آشنایی مقدماتی با Linux، Git ، شبکه و محیط یکسان کار
SQL **و** Database	شناخت Query ، انواع پایگاه داده و چرایی انتخاب آن‌ها
فرهنگ واژگان داده	معرفی اولیه مفاهیم پیش از ورود به مباحث عمیق
Storage**و**Architecture	Lakehouse ، Lake،Warehouse و الگوهای طراحی
Data Processing	Batch، Stream، Kafka ، CDC و دیگر مفاهیم مرتبط
Orchestration	معرفی Airflow و مدیریت اجرای Workflow ها
Data Quality**و**Serving	پایش Pipeline ، استفاده تحلیلی و ارائه داده
مسیر AI Engineering	برنامه جداگانه‌ای که در زمان برگزاری هنوز کامل نهایی نشده بود

این موارد برنامه اعلام‌شده در زمان جلسه هستند و ممکن است تاریخ، مدرس یا ترتیب آن‌ها تغییر کند .مدرس برای بخش Data Engineering همراه با تمرین‌ها، حدود ۴۰ تا ۴۵ ساعت برآورد مطرح کرد؛ این رقم قول قطعی زمان‌بندی نیست.

۱۰ .تمرین‌ها، پروژه و شیوه یادگیری

تمرین‌ها عمدتاً فردی و پروژه‌ها بیشتر گروهی در نظر گرفته شده‌اند .هدف از تمرین، تجربه واقعی حل مسئله است؛ بنابراین مدرس پیشنهاد می‌کند ابتدا خودمان مسئله را حل کنیم و بعد از ابزارهای AI برای بررسی یا یادگیری کمک بگیریم .کمک منتورها و گروه برای پرسیدن سوال و رفع مشکل بخشی از برنامه است .تشکیل تیم و شبکه‌سازی نیز در کنار یادگیری فنی اهمیت دارد.

مدرس وعده استخدام نمی‌دهد .او می‌گوید توانایی فنی، پیگیری، همکاری و شناخت افراد می‌تواند به پیدا کردن فرصت شغلی کمک کند .تجربه او از تفاوت اندازه تیم‌های داده در شرکت‌های مختلف نشان می‌دهد نسخه واحدی برای تعداد اعضا یا مرزبندی تیم وجود ندارد.

۱۱ .پرسش‌های مهم مطرح‌شده در کلاس

1. آیا یک نفر می‌تواند هم**Analyst** ، هم **Scientist** و هم **Engineer** باشد؟
   بله، مخصوصاً در تیم‌های کوچک .اما متخصص شدن در تمام این حوزه‌ها به‌صورت عمیق زمان زیادی می‌خواهد.

2. آیا دوره استخدام را تضمین می‌کند؟
   خیر .دوره به شناخت مسیر، تمرین و ارتباط حرفه‌ای کمک می‌کند؛ نتیجه به تلاش فرد و شرایط بازار نیز وابسته است.
3. آیا پایتون پیش‌نیاز قطعی است؟
   طبق پاسخ مدرس، خیر؛ آشنایی قبلی کمک می‌کند، اما دوره قرار است پیش‌نیازهای لازم را پوشش دهد.
4. آیا جلسات ضبط می‌شوند؟
   در پاسخ به سوال دانشجو، مدرس گفت جلسات ضبط و در اختیار شرکت‌کنندگان قرار می‌گیرد.
5. آیا تمرین‌ها بررسی می‌شوند؟
   برگزاری‌کنندگان در حال طراحی روش ارزیابی بودند؛ برخی تمرین‌ها ممکن است تنها یک پاسخ درست نداشته باشند.
6. بازار کار و آینده نقش‌ها چه می‌شود؟
   مدرس نسبت به پیش‌بینی قطعی محتاط بود و بر ارزش تخصص و توانایی تشخیص مسئله تأکید کرد.
7. آیا دوره برای داده‌های آموزشی یا فایل‌های **Excel** شرکت‌ها کاربرد دارد؟
   مفاهیم زیرساخت و یکپارچه‌سازی داده قابل انتقال‌اند؛ میزان کاربرد هر بخش به هدف واقعی پروژه بستگی دارد.
8. اگر اینترنت مختل شود چه؟
   مدرس درباره ادامه دوره ابراز تمایل کرد، اما گفت شرایط بحرانی می‌تواند روی برنامه تأثیر بگذارد و ارتباط جایگزین نیاز به هماهنگی دارد.

۱۲ .منابع پیشنهادی مدرس

Fundamentals of Data Engineering نوشته Joe Reis و Matt Housley پیشنهاد اصلی برای شروع یادگیری مفاهیم مهندسی داده.

Designing Data-Intensive Applications نوشته :Martin Kleppmann منبع عمیق‌تر برای معماری و سیستم‌های داده؛ مناسب‌تر برای افراد دارای پیش‌زمینه نرم‌افزار.

AI Engineering در کلاس به‌عنوان منبع مرتبط با مسیر مهندسی هوش مصنوعی معرفی شد .برای مشخصات دقیق نویسنده و ویرایش، اسلاید اصلی جلسه ملاک است.

۱۳ .جمع‌بندی جلسه

موضوع محوری این جلسه شناخت مسئله بود، نه انتخاب ابزار .سیستم‌های نرم‌افزاری داده تولید می‌کنند؛ مهندسی داده کمک می‌کند این داده‌ها برای تحلیل و کاربردهای دیگر قابل اعتماد و قابل استفاده شوند .تحلیلگر، دانشمند داده و مهندس AI هر کدام از زاویه‌ای متفاوت با داده کار می‌کنند و مرز نقش‌هایشان در شرکت‌های مختلف می‌تواند همپوشانی داشته باشد .بهترین مسیر یادگیری، شروع از مفهوم و سپس تمرین عملی است.

۱۴ .چک‌لیست مرور

1. می‌توانم تفاوت وظایف کلیAnalyst، Data Scientist ، Data Engineer و AI Engineer را توضیح بدهم.
2. می‌دانم چرا داده ثبت‌شده در سیستم عملیاتی الزاماً آماده تحلیل نیست.
3. پنج نام مرحله در Data Engineering Lifecycle را می‌شناسم.
4. تفاوت کلی ETL و ELT را توضیح می‌دهم.
5. تفاوت بارکاری OLTP و OLAP را می‌فهمم.
6. می‌دانم کیفیت داده و پایش Pipeline چه فایده‌ای دارند.
7. می‌توانم توضیح بدهم چرا تسلط بر مفهوم از حفظ ابزارها مهم‌تر است.

۱۵ .سوال‌های مرور

۱ .وظیفه اصلی Data Engineer در مثال کمپین پیامکی چیست؟

۲ .فرق سؤال‌های معمول تحلیلگر داده و دانشمند داده در مثال فروش چیست؟

۳ .چرا نمی‌توان گفت بدون Data Engineer هیچ داده‌ای در شرکت تولید نمی‌شود؟

۴ AI Engineer .برای ساخت محصول مبتنی بر مدل به چه چیزهایی علاوه بر مدل نیاز دارد؟

۵ .چرا Data-first و AI-first لزوماً دو گزینه کاملاً ناسازگار نیستند؟

۶ Generation .و Ingestion چه تفاوتی دارند؟

۷ .در مثال قیمت‌های ریالی و تومانی، چه خطاهایی ممکن است هنگام Transformation رخ دهند؟

۸ .چه تفاوتی بین Data Warehouse و Data Lake در سطح مفهومی وجود دارد؟

۹ ETL .و ELT در ترتیب چه تفاوتی دارند؟

۱۰ .چرا گزارش تحلیلی سنگین روی سیستم OLTP ممکن است نامناسب باشد؟

۱۱ .اگر Row Count خروجی Pipeline ناگهان نصف شود، چه بررسی‌هایی انجام می‌دهید؟

۱۲ .چرا پروژه گروهی و تمرین فردی هر دو در مسیر یادگیری کاربرد دارند؟